

GUIDE DE SOUTENANCE

Préparation à la présentation orale

Scénario de démonstration, cas concrets à montrer, et réponses préparées aux questions probables du jury

Équipe — Nextdata

Date — 20 juillet 2026

Format officiel — 6 min présentation + démo, 4 min questions, 1 seul présentateur

DOCUMENT INTERNE — PAS UN LIVRABLE DU CAHIER DES CHARGES

Écrans et scénario

Format officiel (protocole d'évaluation BAMIS, reçu le 2026-07-20) : 6 minutes de présentation + démonstration, puis 4 minutes de questions du jury. Une seule personne du groupe présente. L'agenda ci-dessous remplace une version antérieure pensée pour 10-15 minutes — trop long pour le format réel.

Agenda chronométré pour 6 minutes, une seule personne au clavier et à la parole :

TEMPS	ÉTAPE	CONTENU
0:00– 0:30	Problème métier	Le fraudeur ne dépasse jamais le seuil, il le contourne ; le vrai défi est de ne pas signaler à tort marchands, salariés, locataires.
0:30– 1:15	Architecture + résultat clé	3 niveaux (règles → modèle → graphe), seuils jamais en dur, split temporel. Un seul chiffre à retenir : AUC-PR 0,91 (vs 0,42 en baseline).
1:15– 4:15	Démonstration live	Le cœur des 6 minutes — scénario détaillé ci-dessous, dashboard à l'écran du début à la fin.
4:15– 5:15	Résultats et impact	319 transactions bloquées, ~64,5 M MRU protégés, module graphe (24 637 circuits fermés) — chiffrer l'impact concret pour BAMIS.
5:15– 6:00	Limites + clôture	Une phrase honnête (pas de vérité terrain disponible, corrigée par la cohérence croisée règles/scores) plutôt que de survendre.

Ce qui a été volontairement retiré de l'agenda long (toujours disponible pour la session de questions, 4 minutes après) : le détail de l'audit de schéma, le détail des variables, la comparaison des 3 modèles ML, le détail des règles une par une — à sortir uniquement si le jury pose la question correspondante (voir Q&A ci-dessous).

Scénario de démonstration concret (3 minutes, le cœur de la présentation) :

1. (30s) Ouvrir la file d'alertes, sélectionner une transaction à score élevé.
2. (30s) Montrer son score de fraude et ses raisons (5 facteurs).
3. (45s) Ouvrir la fiche du client associé : profil, score de risque, score de valeur, action recommandée.
4. (30s) Montrer sa consommation de seuil (proche de 100 %, tous canaux confondus).
5. (30s) Ouvrir la vue réseau : montrer les comptes liés (mule ou chaîne) — LE moment différenciant (20 % du barème).
6. (15s) Conclure sur l'action recommandée par la matrice de traitement (surveillance, gel, seuil réduit...).

Préparer 2-3 cas concrets à l'avance (pas de recherche live à l'aveugle devant le jury, on n'a pas le temps de chercher en 6 minutes) : un vrai positif clair, et un cas réseau (mule/chaîne) — voir la liste ci-dessous, les deux premiers cas suffisent largement pour le temps disponible.

Cas concrets déjà repérés dans les vraies données, à retenir pour la démonstration :

CLIENT TEL039808 — SCORE DE RISQUE 820/1000 (CRITIQUE)

A reçu de l'argent de **13 expéditeurs différents** et envoyé à 18 destinataires différents (signature collecteur/fan-in, C-03), 22 % de ses opérations collées au seuil du service, écart de 6,3 écarts-types à son historique habituel. Excellent cas pour illustrer le score de risque ET l'explicabilité en une seule fiche client. **Chiffre corrigé le 2026-07-20** : ce cas citait auparavant "544 expéditeurs différents", une valeur fausse produite par un bug confirmé dans `network_features.py` — corrigé et revérifié manuellement. **Si le jury demande le détail des features du modèle ML** : ces deux colonnes faisaient partie des 24 features d'entrée de CatBoost, retirées (24 → 22) et le **modèle réentraîné le 2026-07-20** — AUC-PR holdout quasi inchangé (0,9139 → 0,9130), plus une limite ouverte.

COMPTE AGENT — JUSQU'À 3400 OPÉRATIONS EN 24H, ACTIF DEPUIS 2022

Cas limite idéal pour démontrer la maîtrise des faux positifs : un modèle naïf le signalerait immédiatement, `behavioral_features.py` le reconnaît comme normal une fois comparé à son propre historique sur 4 ans. À rapprocher de la phrase du cahier des charges : *"un marchand reçoit de l'argent de dizaines de personnes [...] tous ces comportements ressemblent à de la fraude sans en être"*.

72 TRANSACTIONS À MONTANT ABERRANT (JUSQU'À 10⁶⁰ MRU)

Trouvées et mises en quarantaine lors de l'audit — bon exemple à citer pour la rigueur de préparation des données ("Difficultés rencontrées"), pas pour la détection de fraude elle-même (transactions `REGISTERED` jamais finalisées, défaut du système source).

COMPTE TEL093693 — SCORE MULE MAXIMAL

259 de ses 273 transactions (95%) sont des "reçu puis renvoyé en moins de 30 minutes" — signature quasi manuelle d'un compte boîte-aux-lettres (C-02). Excellent deuxième cas concret, complémentaire de TEL039808 (celui-là plutôt collecteur fan-in).

24 637 CIRCUITS FERMÉS (A→B→A) DÉTECTÉS EN 7 JOURS

Plusieurs à moins de 3 secondes d'écart avec un montant identique à l'aller et au retour (ex. TEL064889↔TEL068771, 70 MRU dans les deux sens, 0,88 seconde d'écart) — probablement des annulations techniques automatiques plutôt que de la fraude (C-06), mais démontre concrètement que la détection de circuits fonctionne.

UN BUG MÉMOIRE TROUVÉ ET CORRIGÉ PENDANT LE DÉVELOPPEMENT DU MODULE GRAPHE

Bonne histoire de méthode : la première implémentation des circuits fermés (self-join classique) a fait planter le processus par manque de mémoire — une paire agent/hub avec 10 584 transactions produisait plus de 100 millions de lignes intermédiaires. Diagnostiqué en mesurant la distribution réelle, puis remplacé par `merge_asof` — passe de "plante" à 10 secondes sur 1,36M transactions.

Q&A préparées

« Comment avez-vous validé vos scores ? »

Question quasi certaine du jury sur le volet C — voir NOTE_METHODOLOGIQUE.md pour le détail complet des trois corrections.

VERSION COURTE (30 SECONDES)

"On a d'abord construit une méthode évidente — classer chaque client par rapport aux autres. En testant sur les vraies données, on a découvert un problème : presque tous nos indicateurs de risque sont à zéro pour l'immense majorité des clients, donc ce classement les regroupait tous au milieu au lieu de les mettre en bas. Résultat concret : zéro client en 'risque faible'. On l'a corrigé, revérifié, et un deuxième problème est apparu à l'envers sur le score de valeur — corrigé aussi. Pour vérifier que le résultat final tient la route, on a comparé nos scores clients à nos règles de détection de fraude, construites séparément : les clients déjà repérés par les règles ont un score de risque deux fois plus élevé en moyenne, et 13 fois plus de chances d'être classés 'à risque élevé'. Les deux systèmes, indépendants, sont d'accord entre eux."

VERSION LONGUE (SI LE JURY INSISTE)

"Non, on ne peut pas être sûrs à 100% — et on le dit clairement : sans les vraies réponses, qui restent chez le jury, aucune équipe ne peut prouver formellement que son score reflète la vraie fraude. Ce qu'on PEUT montrer, c'est la cohérence interne : deux systèmes construits indépendamment — nos règles sur les transactions individuelles, et notre score agrégé par client — pointent vers les mêmes profils suspects. C'est la meilleure preuve possible sans accès à la vérité terrain, et c'est plus rigoureux que de simplement dire 'ça a l'air bien'."

Pourquoi cette réponse est solide : elle ne cache pas les erreurs (elle les raconte comme preuve de méthode), donne des chiffres précis (zéro client en risque faible → 52,8 % après correction), et admet honnêtement la limite plutôt que de sur-vendre.

« Pourquoi seulement 6-7 règles sur les 16 scénarios F-01 à F-06 / C-01 à C-10 ? »

Question probable — cette sélection peut passer pour arbitraire si elle n'est pas justifiée.

VERSION COURTE (30 SECONDES)

"Ce n'est pas 6 scénarios traités et 10 abandonnés — c'est une répartition sur les 3 niveaux que le cahier des charges recommande lui-même : règles, modèle, graphe. Les scénarios C-02 à C-06 sont traités par notre module graphe, pas par des règles, parce que BAMIS dit lui-même que ces schémas sont invisibles transaction par transaction. Ce qui reste vraiment non couvert, c'est 5 scénarios précis, et pour chacun on peut dire pourquoi : soit la donnée n'existe pas dans le fichier, soit elle existe mais on l'a jugée non fiable après vérification, soit le coût de calcul est trop élevé pour le gain attendu — une décision de priorité assumée, pas un oubli."

VERSION LONGUE (DÉTAIL SCÉNARIO PAR SCÉNARIO)

"F-01 (compte volé) demande de savoir si l'opération vient d'un nouvel appareil ou d'une nouvelle ville — cette information n'existe pas dans le fichier de transactions. F-04 (arnaque) n'est pas détectable même en théorie : la victime envoie l'argent elle-même, volontairement. F-05 (fraude d'un agent) et C-08 (changement de canal) dépendent de la colonne canal — on l'a vérifiée, ses valeurs ne correspondent à aucun canal attendu, donc on a choisi de ne pas construire de règle dessus. C-05 (chaînes de rebond 3+ sauts) et C-10 (fractionnement multi-comptes) sont techniquement faisables avec notre graphe, mais demandent d'explorer des chemins à plusieurs sauts sur 163 000 comptes, un coût de calcul beaucoup plus élevé pour un gain marginal jugé plus faible compte tenu du temps disponible."

Pourquoi cette réponse est solide : elle recadre la question (ce n'est pas "6 sur 16", c'est "réparti sur 3 niveaux + 5 exclusions justifiées une par une"), et chaque exclusion a une cause vérifiable et différente plutôt qu'une réponse générique du type "pas eu le temps".

« Comment avez-vous décidé quel scénario va à quel niveau (règles / modèle / graphe) ? »

VERSION COURTE (30 SECONDES)

"Chaque niveau répond à un type de question différent. Le niveau 1 (règles) traite ce qu'on peut voir sur une seule transaction avec un critère clair. Le niveau 2 (modèle) combine tous ces indicateurs ensemble pour capter des patterns qu'aucune règle écrite à la main n'attraperait seule. Le niveau 3 (graphe) traite ce qui n'existe QUE dans la relation entre plusieurs comptes — un compte qui collecte de l'argent de centaines d'autres, une chaîne A vers B vers C, un circuit qui revient à son point de départ. Ce dernier type est par nature invisible transaction par transaction."

VERSION LONGUE (DÉTAIL PAR SCÉNARIO)

"Niveau 1 : R1/R2 sont des comparaisons directes à un seuil officiel. C-01 (fractionnement) et C-07 (rafale) sont des comptages sur une courte fenêtre. F-03 (nouveau bénéficiaire + gros montant) est une combinaison de deux conditions booléennes. Tout ça s'exprime comme une règle simple — rapide et 100% explicable, ce que le cahier des charges exige."

Niveau 2 : le modèle apprend à pondérer et combiner tous les indicateurs numériques ensemble (hors les règles elles-mêmes, pour éviter la fuite de données). Nécessaire parce qu'une règle est rigide — un seuil fixe peut être contourné en restant juste en dessous — alors que le modèle peut repérer une transaction légèrement anormale sur cinq indicateurs à la fois."

Niveau 3 : C-03 (fan-in) et C-04 (fan-out) sont littéralement des comptes de connexions entrantes/sortantes dans un graphe. C-05 (chaîne de rebond) demande de suivre un chemin sur plusieurs comptes. C-06 (circuit fermé) est un cycle. Ces scénarios n'ont simplement aucun sens en dehors d'une représentation en graphe — BAMIS le dit lui-même : 'les schémas C-02 à C-06 et C-09 sont invisibles si l'on regarde les transactions une par une'."

Pourquoi cette réponse est solide : elle montre qu'on a choisi le niveau en fonction de la nature du signal, pas au hasard — et elle s'appuie sur une phrase que BAMIS a écrite lui-même.

« Comment justifiez-vous le choix de CatBoost ? »

VERSION COURTE (30 SECONDES)

"On a choisi CatBoost pour deux raisons concrètes : c'est la famille de modèles (gradient boosting) la plus utilisée dans l'industrie pour ce genre de données — des transactions en tableau, pas des images ni du texte — et elle a une technique interne pensée pour limiter le surapprentissage sur une étiquette imparfaite, ce qui est exactement notre cas avec le pseudo-label. Et surtout, on ne l'a pas choisi les yeux fermés : on l'a comparé à un modèle de référence basique et à une régression logistique, et CatBoost gagne largement (0,91 contre 0,42 et 0,31)."

VERSION LONGUE (POURQUOI CATBOOST PRÉCISÉMENT)

"Pour des données en tableau, les modèles de la famille gradient boosting (CatBoost, XGBoost, LightGBM) sont l'état de l'art reconnu, bien avant le deep learning. CatBoost utilise l'ordered boosting, pensé pour limiter le surapprentissage quand l'étiquette d'entraînement est imparfaite — exactement notre cas avec le pseudo-label. Et il demande peu de réglage pour un bon résultat, un vrai avantage avec 2 jours devant nous. LightGBM était notre deuxième choix envisagé, XGBoost et le stacking ont été jugés en dernier recours, plus de risque d'erreur pour un gain estimé faible vu le temps restant."

Pourquoi cette réponse est solide : elle ne se limite pas à "c'est un bon modèle" — elle justifie par la nature des données, une particularité technique pertinente, et une comparaison chiffrée réelle.

Point de vigilance, à ne pas dire : ne pas mentionner "CatBoost gère nativement les catégories" — le modèle ne reçoit que 22 colonnes numériques déjà calculées, aucune colonne catégorielle brute ne lui est passée directement. Si le jury demande à voir le code, cet argument ne tiendrait pas.

« Sur quoi vous êtes-vous basés pour dire que 3 règles sur 7, c'est le seuil de blocage ? »

VERSION COURTE (30 SECONDES)

"Honnêtement, ce seuil n'est pas issu d'une optimisation statistique — le seuil à 2 règles sert déjà à entraîner le modèle, donc pour illustrer une politique d'action plus stricte dans le dashboard, on a pris un cran au-dessus. Mais on a vérifié après coup si notre modèle validé (0,91) est d'accord avec ce choix : il classe déjà 99,8% des transactions à 2 règles comme quasi certainement frauduleuses (score > 50%), quasiment autant qu'à 3 règles (100%). Le vrai saut, selon le modèle, se situe entre 1 et 2 règles, pas entre 2 et 3. Notre seuil à 3 est donc volontairement plus prudent — on préfère sous-agir que sur-bloquer des clients honnêtes."

CHIFFRES À L'APPUI SI LE JURY DEMANDE LE DÉTAIL

RÈGLES DÉCLENCHÉES	SCORE MOYEN DU MODÈLE	% AVEC SCORE > 50%
0	0,04%	0,0%
1	11,8%	11,8%
2	98,7%	99,8%
3	99,9%	100%
4	99,99%	100%

Pourquoi cette réponse est solide : elle ne prétend pas à une justification qu'on n'a pas, mais transforme la question en vérification empirique réelle, présentée comme un choix de prudence assumé plutôt que caché.

« D'où viennent vos multiplicateurs de seuil (×1.5, ×0.7, ×0...) pour le bonus volet B ? »

VERSION COURTE (30 SECONDES)

"Ce ne sont pas des valeurs mesurées sur les données — on l'assume complètement. Ce qui est réfléchi, c'est l'ordre et l'écart entre elles : ils suivent exactement la sévérité croissante de la matrice de traitement du cahier des charges, du moins sévère au plus sévère. Le chiffre exact est un point de départ raisonnable, pensé pour être ajusté par la direction des risques de BAMIS — c'est pour ça qu'il est dans config.yaml et pas codé en dur dans le script."

DÉTAIL DES VALEURS CHOISIES ET LEUR LOGIQUE

ACTION (MATRICE VOLET C)	MULTIPLICATEUR	LOGIQUE
Seuil majoré	×1.5	+50%, désengorge un bon client sans vider le seuil de son sens
Seuil normal	×1.0	Cas de référence, aucun changement
Surveillance	×1.0	Risque encore modéré : on regarde de plus près sans pénaliser financièrement
Surveillance renforcée	×0.85	Un cran sous la surveillance simple : risque "Élevé"
Seuil réduit	×0.7	-30%, ralentit sans bloquer l'usage normal
Seuil minimal	×0.4	-60%, très strict, réservé à Bronze + risque élevé
Gel, investigation	×0	Correspond littéralement au mot "Gel" — validation manuelle requise

Pourquoi cette réponse est solide : elle ne prétend pas à une calibration qu'on n'a pas faite, mais montre un choix cohérent et documenté, conçu pour être corrigé par un humain métier plutôt que figé dans le code.

Version équipe (débutants) — l'analogie du bulletin scolaire, à utiliser pour expliquer le bug de normalisation en interne sans jargon : pour chaque client, on donne deux notes sur 1000 — comme un bulletin scolaire, mais avec deux matières (risque et valeur), chacune moyenne pondérée de 5 "matières" avec son propre coefficient. La première fois, résultat impossible : aucun client classé "peu risqué", parce que la méthode comparait chaque client aux autres comme un classement de classe — et un gros paquet d'élèves à égalité sur 0/20 se retrouve statistiquement au milieu du classement, pas en dernière position. Corrigé en comparant à une échelle fixe plutôt qu'à un classement. Message pour l'équipe : ce n'est pas grave de ne pas réussir du premier coup — ce qui compte, c'est d'avoir vérifié, compris, et corrigé.