

PRÉPARATION SOUTENANCE

Questions potentielles du jury

Checklist de ~38 questions et réponses courtes, organisées par thème, pour ne jamais être pris au dépourvu

Équipe — Nextdata

Date — 20 juillet 2026

Format réel — 4 minutes de questions, 2-4 posées

DOCUMENT INTERNE — PAS UN LIVRABLE DU CAHIER DES CHARGES

Complément à **GUIDE_SOUTENANCE.md** (les 6 questions les plus probables, en détail). Le jury n'aura que 4 minutes de questions — il n'en posera que 2 à 4. Ce document sert à ne pas être pris au dépourvu, pas à tout réciter. ★ = très probable, déjà traité en détail dans **GUIDE_SOUTENANCE.md**.

A. Préparation des données

Comment avez-vous vu que le fichier avait 26 colonnes au lieu de 23 ?

On a compté le nombre de champs réels sur les 1,6M lignes, au lieu de faire confiance au dictionnaire fourni. On a trouvé 26 colonnes, pas 23.

Comment avez-vous géré les lignes avec une date ou un montant aberrant ?

On les a mises de côté avant tout calcul. Une seule valeur fausse peut fausser tout l'historique d'un client.

Pourquoi ne pas avoir utilisé **CHANNEL_TYPE ?**

On l'a vérifiée avant de l'écarter. On a cherché les valeurs attendues (APP, USSD, AGENT, WHATSAPP) dans tout le fichier — elles n'existent nulle part. La colonne est vide à 97% sur notre échantillon, et le peu qu'elle contient ressemble à des résidus du bug de date, pas à des noms de canal. On préfère le dire clairement plutôt que d'inventer une règle sur une donnée qu'on ne comprend pas. Conséquence : on ne détecte pas C-08 (changement de canal).

Comment distinguez-vous une transaction interne d'une externe (GIMTEL) ?

Simple : si **DESTINATION_CUSTOMER** est vide, c'est interne. S'il est rempli, c'est externe.

Que faites-vous des transactions rejetées ou en attente ?

On les exclut de tous les calculs de cumul. Une transaction rejetée n'a jamais fait bouger d'argent.

B. Volet A — règles, modèle, graphe

Pourquoi CatBoost et pas XGBoost/LightGBM/Random Forest ?

Pour ce type de données (des transactions en tableau), le gradient boosting est la référence. CatBoost a une technique qui limite les erreurs quand l'étiquette d'entraînement n'est pas parfaite — c'est notre cas, puisqu'on n'a pas la vraie liste des fraudes. Et on ne l'a pas choisi au hasard : comparé à une baseline simple (AUC-PR 0,42) et à une régression logistique (0,31), CatBoost gagne largement (0,91).

À ne jamais dire : que CatBoost "gère nativement les catégories". Vrai en général, pas dans notre cas — le modèle ne reçoit que des chiffres déjà calculés.

Comment avez-vous construit vos exemples de fraude sans vérité terrain ?

Une transaction est comptée comme "exemple de fraude" si au moins 2 de nos 7 règles se déclenchent en même temps. Ça représente 0,47% des transactions, proche du "~1%" donné en exemple par le cahier des charges.

Comment évitez-vous que le modèle "triche" en apprenant le futur ?

Trois protections : on entraîne sur le passé et on teste sur une période plus récente, jamais l'inverse. On laisse 7 jours d'écart entre les deux. Et on exclut nos propres règles des variables du modèle, sinon il recopierait juste leur formule.

À quelle fréquence faut-il réentraîner le modèle ?

Pas testé précisément — à discuter avec BAMIS selon la vitesse à laquelle les fraudeurs changent de méthode. Une piste raisonnable : une fois par mois.

Le score est-il une vraie probabilité ?

Non, c'est un score de classement, pas calibré comme une vraie probabilité. Ça ne change rien à notre résultat (AUC-PR), mais c'est une limite à signaler si la question arrive.

Comment le module graphe tiendrait-il avec 10 fois plus de données ?

On a déjà eu ce problème et on l'a réglé : la première version plantait par manque de mémoire sur une grosse paire de comptes. On l'a remplacée par une méthode plus efficace (`merge_asof`), qui tient en 10 secondes sur 1,36M transactions.

Pourquoi seulement des circuits courts ($A \rightarrow B \rightarrow A$) et pas des chaînes plus longues ?

Question de temps. Chercher des chaînes plus longues sur 163 000 comptes coûte beaucoup plus cher en calcul, pour un gain qu'on a jugé plus faible avec le temps qu'on avait.

C. Volet B — budget et seuils

D'où vient le seuil mensuel, puisqu'il n'existe pas dans le fichier fourni ?

On l'a estimé à 30 fois le seuil journalier. C'est une hypothèse assumée, à remplacer dès que BAMIS donne un vrai chiffre.

Un client qui dépasse son seuil est-il bloqué automatiquement ?

Non. On génère une alerte, mais la décision de bloquer reste à BAMIS. On ne l'automatise pas.

Et le fractionnement sur plusieurs comptes du même client (C-10) ?

Pas traité, faute de temps. Possible avec le module graphe, mais pas fait dans cette version.

D. Volet C — classement client

Pourquoi prendre le maximum et pas la moyenne des indicateurs ?

Pour ne pas diluer un signal fort. Un client extrême sur un seul point ne doit pas paraître "normal" juste parce que ses autres indicateurs sont bas.

Pourquoi 175 689 clients dans le fichier, alors que 40 866 seulement ont fait une transaction ?

On a élargi exprès. Un compte qui ne fait QUE recevoir de l'argent de beaucoup de gens différents est justement le profil "collecteur" (C-03) que le cahier des charges demande de détecter.

Comment traitez-vous un nouveau client sans historique ?

Ses indicateurs de comportement ne sont pas calculables à sa première transaction — le système le signale. Pas de règle spéciale au-delà de ça, c'est une limite qu'on assume.

E. Validation

Pourquoi 3 découpages temporels et pas 5 ou 10 ?

Compromis avec le temps qu'on avait (2 jours). 3 suffisent pour voir si le résultat est stable.

Pourquoi 7 jours d'écart entre entraînement et test ?

Marge de sécurité, pour être sûr qu'aucune donnée calculée en retard ne passe d'un côté à l'autre par erreur.

Comment savez-vous que le modèle ne va pas se dégrader avec le temps ?

On ne le sait pas précisément — pas de suivi automatique mis en place. C'est une limite assumée, pas résolue.

F. Limites déjà assumées

★ Si le jury avait la vraie liste des fraudes, votre 0,91 tiendrait-il encore ?

→ Réponse détaillée dans `GUIDE_SOUTENANCE.md` : on ne peut pas garantir un chiffre exact, mais nos règles et notre modèle, construits séparément, pointent vers les mêmes comptes suspects.

Le bug dans `network_features.py`, quel a été son impact réel ?

Mesuré, pas juste supposé. On a retiré les 2 colonnes fausses et réentraîné le modèle le 2026-07-20. Résultat : quasiment aucun changement (0,9139 → 0,9130). Ces deux colonnes ne servaient à rien.

★ D'où viennent vos multiplicateurs de seuil ($\times 1.5$, $\times 0.7...$) ?

→ Réponse détaillée dans `GUIDE_SOUTENANCE.md` : pas mesurés sur les données, mais l'ordre suit la logique de la matrice du cahier des charges.

G. Bonus et reproductibilité

Le dashboard est-il connecté en direct aux données ?

Non, c'est un export à partir des vrais résultats du pipeline. Pas de connexion en temps réel — normal pour un datathon, pas une vraie production.

Comment le jury peut-il relancer tout votre travail ?

Une seule commande : `python scripts/run_all.py`. Testée de bout en bout, 13 minutes, tout fonctionne.

Pourquoi Python ?

Les bonnes bibliothèques existent déjà pour tout faire : règles, machine learning, graphe. Ça permet un seul pipeline cohérent et testable.

H. Questions pièges

Avez-vous chiffré le coût d'une fausse alerte pour BAMIS ?

Non, pas en argent. On donne le nombre d'alertes générées à plusieurs seuils, pour que BAMIS fasse ce choix eux-mêmes selon leur propre coût.

Comment votre solution s'adapterait à un nouveau service demain ?

Facilement. Les seuils viennent d'un fichier, pas du code. Il suffit d'ajouter une ligne.

Qu'est-ce qui vous a le plus surpris ?

Le décalage entre 23 et 26 colonnes, invisible sans vérifier chaque valeur une par une. Et le bug réseau, correct sur un petit échantillon mais faux à grande échelle.

Avec 5 jours au lieu de 2, qu'auriez-vous fait de plus ?

Calibrer vraiment les probabilités, détecter les chaînes plus longues (C-05) et le fractionnement multi-comptes (C-10), et connecter le vrai score du module graphe au score client.

Comment vous êtes-vous répartis le travail en équipe ?

Réponse à adapter selon votre organisation réelle — le jury veut vérifier que ce n'est pas le travail d'une seule personne. Restez concret : qui a fait quoi (données, modèle, dashboard, rapport).

Votre modèle peut-il désavantager injustement certains clients ?

C'est un vrai risque avec ce genre de système, on ne le nie pas. On compare toujours un client à son propre historique, pas à une moyenne globale — ça évite de pénaliser quelqu'un juste parce qu'il est différent des autres. Mais on n'a pas testé formellement l'équité du modèle entre différents profils de clients, c'est une limite honnête.

Pourquoi votre solution mériterait de gagner ?

Trois choses concrètes : un AUC-PR mesuré et vérifié (0,91), un module graphe qui détecte vraiment des mules et des circuits (pas juste des règles), et une méthode honnête — chaque limite est documentée, pas cachée.